Профилирование и мониторинг Spark Job

KARPOV.COURSES

Profiling

Профилирование — сбор характеристик работы программы, таких как время выполнения отдельных фрагментов (wikipedia)

- Spark написан на Scala -> все средства для профилирования JVM программ нам доступны
- Сбор информации и выполнении обычно делают на уровне
  - ОС (top, vmstat, lsof, tcpdump, netstat, iostat и т.д.)
  - JVM (обычно делается с помощью agent)
  - конкретной Spark Job
  - кластера (YARN или k8s)

Profiling OS level

- **Достоинства**
  - честные метрики
  - родные для Linux утилиты
- **Недостатки**
  - требуется установка всех необходимых утилит на все сервера / контейнеры
  - организация отправки метрик в единое хранилище
  - зачастую трудно изолировать конкретный процесс (можно промерить общую нагрузку включая другие работающие процессы)

Profiling JVM level

- **Достоинства**
  - родные для JVM средства (jconsole, visualvm, Java Flight Recorder и т.д.)
  - очень подробная детализация (вплоть до вызова native кода)
  - можно использовать для любых JVM программ
- **Недостатки**
  - требуется подключение к конкретным серверам и процессам (что очень затруднительно в кластерах)
  - предварительно желательно локализовать проблему (для подключения к конкретному executor)
  - организация сбора метрик и дампов памяти в единое хранилище (зачастую требуется много дискового пространства)
  - можно “утонуть” в обилии информации, требуется опыт для эффективного анализа

Profiling Job level

- **Достоинства**
  - базовые метрики можно посмотреть как online в процессе выполнения Job, так и по завершении на History Server
  - есть графовое представление выполняемых задач
  - работает для любых Job вне зависимости от используемого ЯП
- **Недостатки**
  - не всегда доступно (закрытый production контур)
  - гранулярность (job -> stage -> task)
  - требуются дополнительные настройки инфраструктуры (log aggregation, histroty server и т.д.)

Profiling cluster level

- **Достоинства**
  - удобно для высокоуровнего анализа и мониторинга утилизации ресурсов
  - централизация
- **Недостатки**
  - зачастую трудно отделить проблемы job от проблем инфраструктуры
  - при гонке за ресурсы картина может искажаться
  - очень трудно оценивать производительность задач при коммуникации с внешними системами (БД, S3 / HDFS, Kafka и т.д.)

Что хочется?

- сбор метрик в едином хранилище
- добавлять свои метрики
- включать / отключать метрики по необходимости
- подробная аналитика (группировка, временной отрезок, скользящие окна и т.д.)
- удобные средства визуализации
- минимальные изменения в коде (в идеале - без изменений)

Возможные решения

- сбор метрик в едином хранилище
  - использовать push / pull доставку в time-series database (InfluxDB, Prometheus)
- добавлять свои метрики
  - поддержка с Spark 3.0 (требуется дополнительный код, что логично)
- включать / отключать метрики по необходимости
  - метрики необходимо группировать по приемнику (sink). Приемники можно включать / отключать на момент запуска job
- подробная аналитика (группировка, временной отрезок, скользящие окна и т.д.)
  - TSDB поддерживают широкие аналитические возможности
- удобные средства визуализации
  - существуют легковесные средства визуализации, например Grafana
- минимальные изменения в коде (в идеале - без изменений)
  - настройка приемников (sink) доступна как параметр запуска, для отладки можно выводить в консоль, а на production - statsd, InfluxDB и т.д.
  - подключение разного рода профайлеров производится через java agent (jar + параметры запуска)

Обычный flow анализа

- **Смотрим на YARN Resource Manager UI**

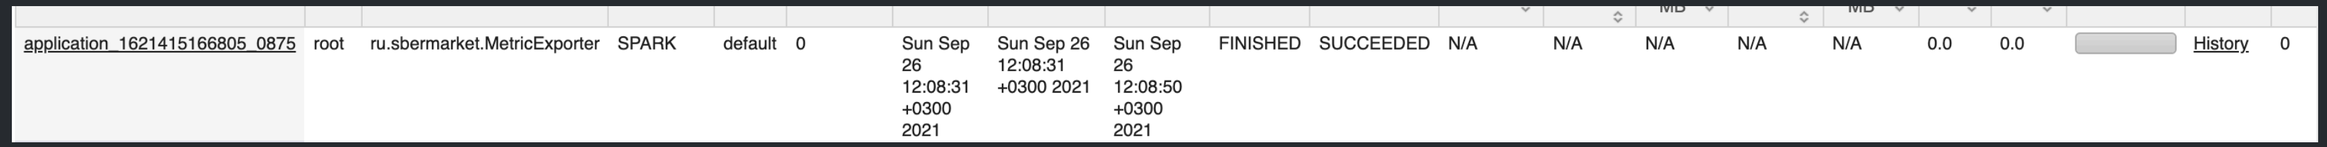

application_1621415166805_0875	root	ru.sbermarket.MetricExporter	SPARK	default	0	Sun Sep 26 12:08:31 +0300 2021	Sun Sep 26 12:08:31 +0300 2021	Sun Sep 26 12:08:50 +0300 2021	FINISHED	SUCCEEDED	N/A	N/A	N/A	N/A	N/A	0.0	0.0		History	0

- **заходим в History (Application Master если задание еще работает)**

- **смотрим на jobs, выбираем подозрительную job**

Обычный flow анализа

Spark Jobs (?)

User: root
Total Uptime: 1.3 min
Scheduling Mode: FIFO
Active Jobs: 1
Completed Jobs: 1

▾ Event Timeline

☐ Enable zooming

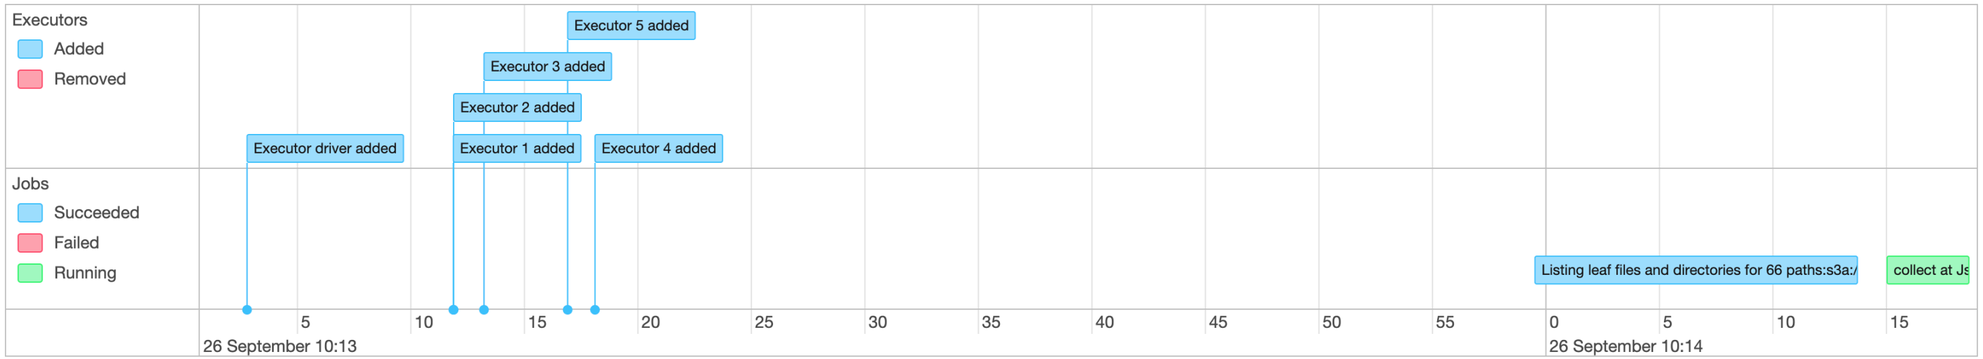

▾ Active Jobs (1)

Job Id ▾	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
1	collect at JsonPriceStockImporter.scala:129 collect at JsonPriceStockImporter.scala:129 (kill)	2021/09/26 10:14:15	4 s	0/2	3/359 (11 running)

▾ Completed Jobs (1)

Job Id ▾	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
0	Listing leaf files and directories for 66 paths: s3a://content-db/price_stock/retailer_name=agrocomplex/dt=2021-09-26, ... collect at JsonPriceStockImporter.scala:129	2021/09/26 10:13:59	14 s	1/1	66/66

Обычный flow анализа

Details for Job 1

Status: RUNNING
Active Stages: 1
Pending Stages: 1

▸ Event Timeline
▸ DAG Visualization

▾ Active Stages (1)

Stage Id	Description	Submitted	Duration	Tasks: Succeeded/Total	Input	Output	Shuffle Read	Shuffle Write
1	collect at JsonPriceStockImporter.scala:129 +details (kill)	2021/09/26 10:14:15	16 s	94/159 (11 running)	6.5 MB			1070.9 KB

▾ Pending Stages (1)

Stage Id	Description	Submitted	Duration	Tasks: Succeeded/Total	Input	Output	Shuffle Read	Shuffle Write
2	collect at JsonPriceStockImporter.scala:129 +details	Unknown	Unknown	0/200				

Обычный flow анализа

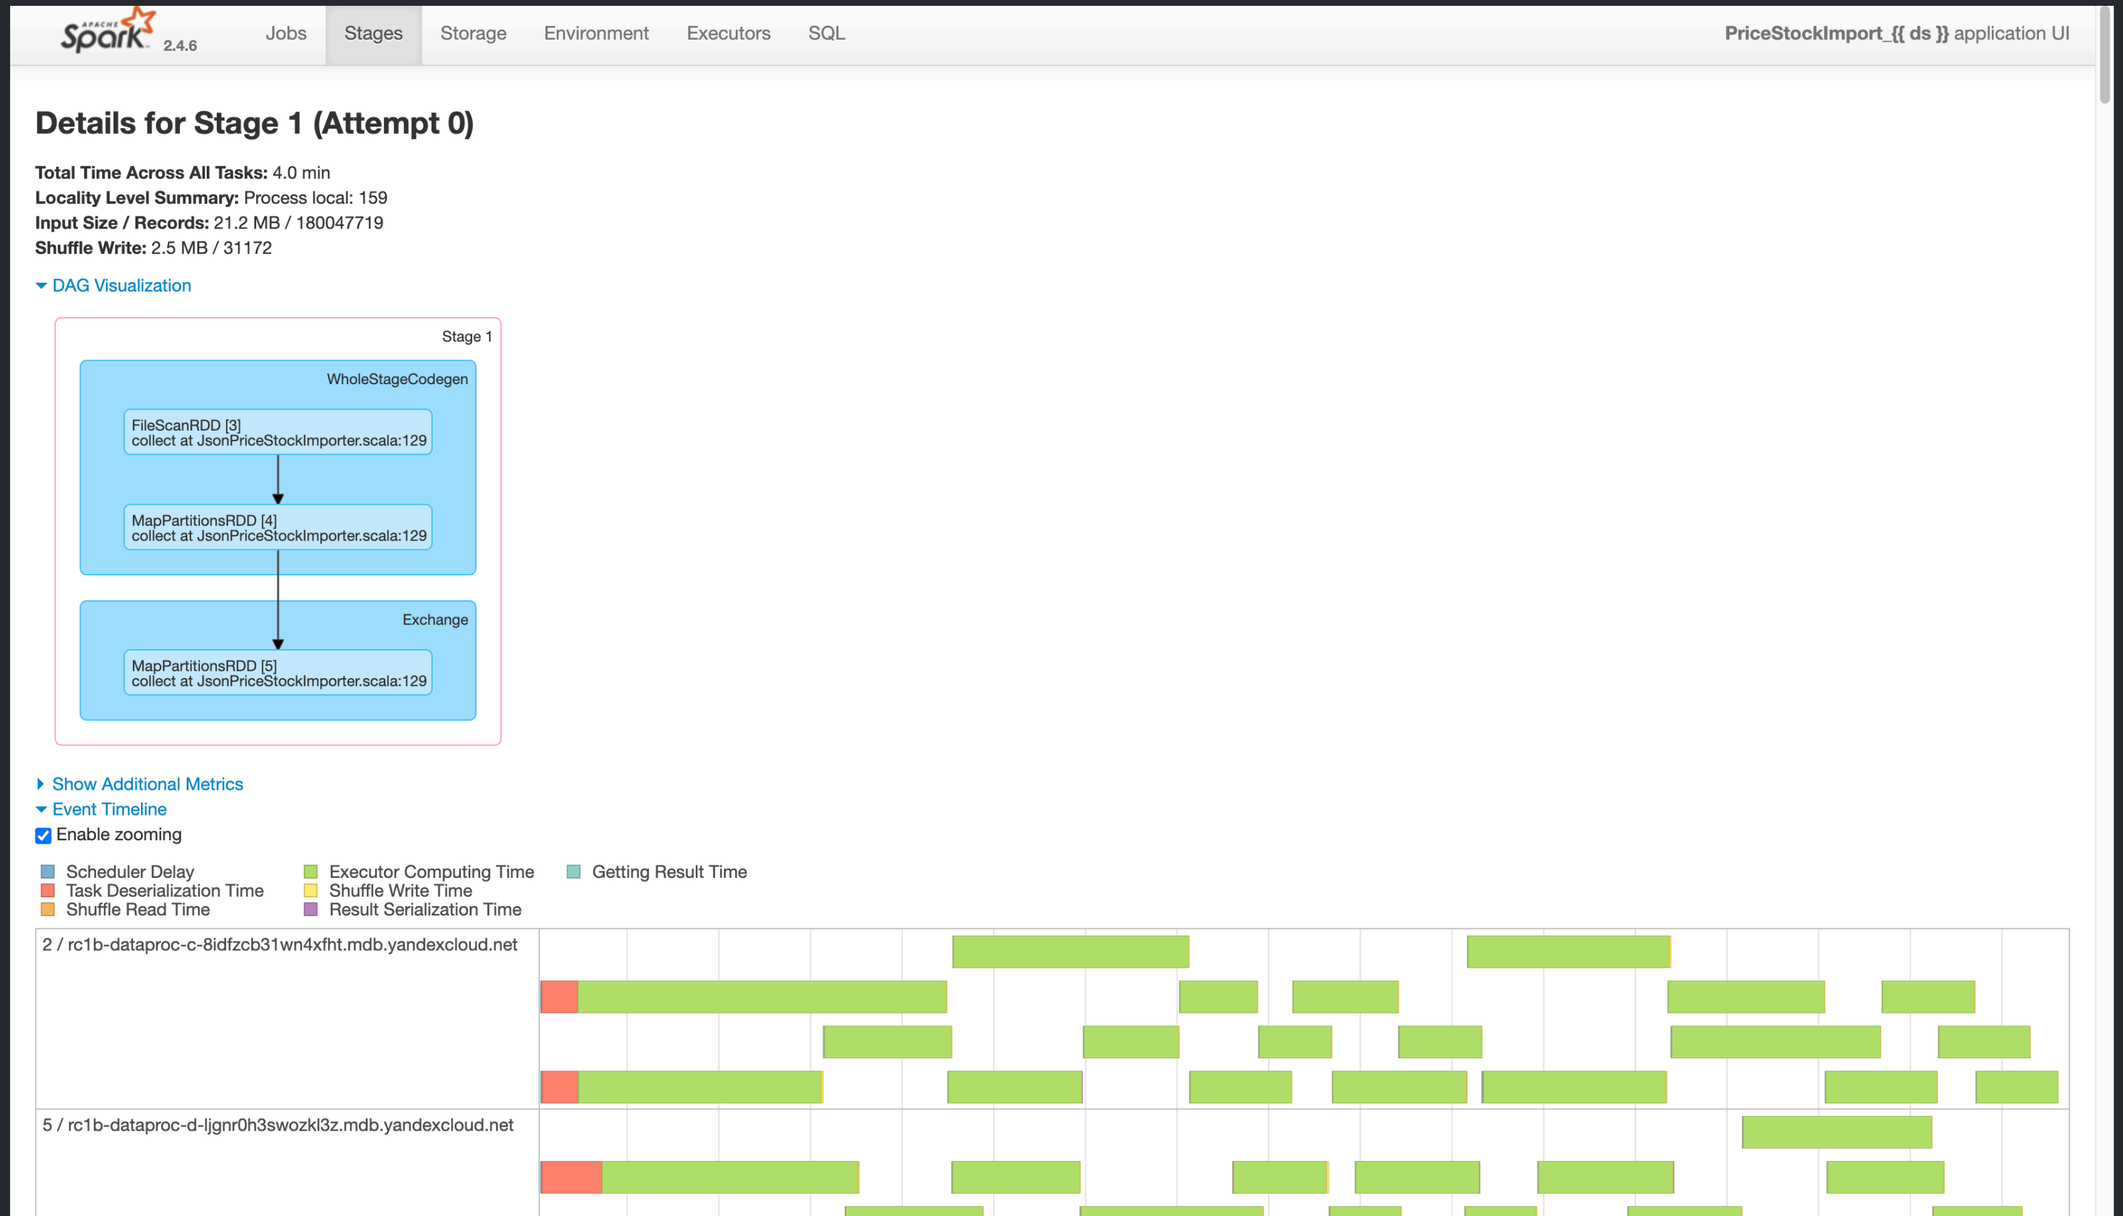

Обычный flow анализа

Summary Metrics for 159 Completed Tasks

Metric	Min	25th percentile	Median	75th percentile	Max
Duration	0.3 s	1.0 s	1 s	2 s	5 s
Scheduler Delay	3 ms	5 ms	6 ms	7 ms	28 ms
Task Deserialization Time	0 ms	2 ms	2 ms	3 ms	0.7 s
GC Time	0 ms	0 ms	0 ms	8 ms	0.4 s
Result Serialization Time	0 ms	0 ms	0 ms	0 ms	2 ms
Getting Result Time	0 ms	0 ms	0 ms	0 ms	0 ms
Peak Execution Memory	64.3 MB	64.3 MB	64.3 MB	64.3 MB	64.3 MB
Input Size / Records	42.2 KB / 225	55.8 KB / 705925	94.1 KB / 942892	127.4 KB / 1128508	1034.9 KB / 4098613
Shuffle Write Size / Records	1284.0 B / 9	6.9 KB / 49	12.6 KB / 101	18.8 KB / 166	55.6 KB / 1317

Aggregated Metrics by Executor

Executor ID ▲	Address	Task Time	Total Tasks	Failed Tasks	Killed Tasks	Succeeded Tasks	Input Size / Records	Shuffle Write Size / Records	Blacklisted
1 stdout stderr	rc1b-dataproc-c-97cq7ba0wj61569n.mdb.yandexcloud.net:37670	49 s	33	0	0	33	4.3 MB / 38500945	534.1 KB / 6222	false
2 stdout stderr	rc1b-dataproc-c-8idfzcb31wn4xfht.mdb.yandexcloud.net:35373	48 s	32	0	0	32	4.0 MB / 39353280	499.5 KB / 6150	false
3 stdout stderr	rc1b-dataproc-c-e6oft4h554f686b7.mdb.yandexcloud.net:40540	50 s	33	0	0	33	4.4 MB / 34078689	518.8 KB / 6532	false
4 stdout stderr	rc1b-dataproc-d-e366rgs7pfnmjtf0.mdb.yandexcloud.net:33036	54 s	29	0	0	29	4.7 MB / 32331460	490.4 KB / 5976	false
5 stdout stderr	rc1b-dataproc-d-ljgnr0h3swozkl3z.mdb.yandexcloud.net:39406	48 s	32	0	0	32	3.9 MB / 35783345	508.8 KB / 6292	false

Tasks (159)

Page: 1 2 > 2 Pages. Jump to 1 . Show 100 items in a page. Go

Index ▲	ID	Attempt	Status	Locality Level	Executor ID	Host	Launch Time	Duration	Scheduler Delay	Task Deserialization Time	GC Time	Result Serialization Time	Getting Result Time	Peak Execution Memory	Input Size / Records	Write Time	Shuffle Write Size / Records	Errors
0	66	0	SUCCESS	PROCESS_LOCAL	1	rc1b-dataproc-c-97cq7ba0wj61569n.mdb.yandexcloud.net stdout stderr	2021/09/26 10:14:15	4 s	18 ms	0.4 s		0 ms	0 ms	64.3 MB	78.3 KB / 1166024	19 ms	19.8 KB / 167	
1	67	0	SUCCESS	PROCESS_LOCAL	4	rc1b-dataproc-d-e366rgs7pfnmjtf0.mdb.yandexcloud.net stdout	2021/09/26 10:14:15	4 s	17 ms	0.6 s		0 ms	0 ms	64.3 MB	75.8 KB / 1089468	16 ms	18.0 KB / 161	

Обычный flow анализа

Spark 2.4.6 | Jobs | Stages | Storage | Environment | Executors | SQL | PriceStockImport_{{ ds }} application UI

Storage

RDDs

ID	RDD Name	Storage Level	Cached Partitions	Fraction Cached	Size in Memory	Size on Disk
11	*(1) Project [external_offer_id#161, offer_name#162, offer_items_per_pack#163L, offer_pack_type#164, offer_vat#165, instamart_sku_id#166L, instamart_sku#167, instamart_product_type#168, retailer_regular_price_per_item#169, retailer_regular_price_per_kilo#170, retailer_regular_price_per_pack#171, retailer_partner_price_per_item#172, retailer_partner_price_per_kilo#173, retailer_partner_price_per_pack#174, retailer_discount_price_per_item#175, retailer_discount_price_per_kilo#176, retailer_discount_price_per_pack#177, retailer_discount_start#178, retailer_discount_end#179, shop_stock#180, max_shop_stock#181, min_shop_stock#182, instamart_regular_price_per_item#183, instamart_regular_price_per_kilo#184, ... 16 more fields] +- *(1) Project [external_offer_id#161, offer_name#162, offer_items_per_pack#163L, offer_pack_type#164, offer_vat#165, instamart_sku_id#166L, instamart_sku#167, instamart_product_type#168, retailer_regular_price_per_item#169, retailer_regular_price_per_kilo#170, retailer_regular_price_per_p...	Memory Deserialized 1x Replicated	3	100%	35.8 KB	0.0 B
40	*(1) Project [external_offer_id#4838, offer_name#4839, offer_items_per_pack#4840L, offer_pack_type#4841, offer_vat#4842, instamart_sku_id#4843L, instamart_sku#4844, instamart_product_type#4845, retailer_regular_price_per_item#4846, retailer_regular_price_per_kilo#4847, retailer_regular_price_per_pack#4848, retailer_partner_price_per_item#4849, retailer_partner_price_per_kilo#4850, retailer_partner_price_per_pack#4851, retailer_discount_price_per_item#4852, retailer_discount_price_per_kilo#4853, retailer_discount_price_per_pack#4854, retailer_discount_start#4855, retailer_discount_end#4856, shop_stock#4857, max_shop_stock#4858, min_shop_stock#4859, instamart_regular_price_per_item#4860, instamart_regular_price_per_kilo#4861, ... 16 more fields] +- *(1) Project [external_offer_id#4838, offer_name#4839, offer_items_per_pack#4840L, offer_pack_type#4841, offer_vat#4842, instamart_sku_id#4843L, instamart_sku#4844, instamart_product_type#4845, retailer_regular_price_per_item#4846, retailer_regular_price_per_kilo#...	Memory Deserialized 1x Replicated	9	75%	108.5 MB	0.0 B

Обычный flow анализа

Spark 2.4.6 | Jobs | Stages | Storage | Environment | Executors | SQL | PriceStockImport_{{ ds }} application UI

Executors

▸ Show Additional Metrics

Summary

	RDD Blocks	Storage Memory	Disk Used	Cores	Active Tasks	Failed Tasks	Complete Tasks	Total Tasks	Task Time (GC Time)	Input	Shuffle Read	Shuffle Write	Blacklisted
Active(6)	25	195.9 MB / 15.7 GB	0.0 B	10	4	0	869	873	8.1 min (10 s)	1.2 GB	2.6 MB	2.6 MB	0
Dead(0)	0	0.0 B / 0.0 B	0.0 B	0	0	0	0	0	0 ms (0 ms)	0.0 B	0.0 B	0.0 B	0
Total(6)	25	195.9 MB / 15.7 GB	0.0 B	10	4	0	869	873	8.1 min (10 s)	1.2 GB	2.6 MB	2.6 MB	0

Executors

Show 20 entries Search:

Executor ID	Address	Status	RDD Blocks	Storage Memory	Disk Used	Cores	Active Tasks	Failed Tasks	Complete Tasks	Total Tasks	Task Time (GC Time)	Input	Shuffle Read	Shuffle Write	Logs	Thread Dump
driver	rc1b-dataproc-c-ccxzsurfa94e4nuh.mdb.yandexcloud.net:36134	Active	0	479.9 KB / 2.4 GB	0.0 B	0	0	0	0	0	0 ms (0 ms)	0.0 B	0.0 B	0.0 B	stdout stderr	Thread Dump
1	rc1b-dataproc-c-97cq7ba0wj61569n.mdb.yandexcloud.net:37670	Active	6	48 MB / 2.7 GB	0.0 B	2	1	0	218	219	1.7 min (2 s)	250.4 MB	582.8 KB	547.1 KB	stdout stderr	Thread Dump
2	rc1b-dataproc-c-8idfzcb31wn4xfht.mdb.yandexcloud.net:35373	Active	6	38 MB / 2.7 GB	0.0 B	2	1	0	228	229	1.7 min (2 s)	355.4 MB	535.3 KB	511.7 KB	stdout stderr	Thread Dump
3	rc1b-dataproc-c-e6oft4h554f686b7.mdb.yandexcloud.net:40540	Active	5	40.3 MB / 2.7 GB	0.0 B	2	1	0	180	181	1.5 min (2 s)	197.7 MB	423.7 KB	531.5 KB	stdout stderr	Thread Dump
4	rc1b-dataproc-d-e366rgs7pfnmjtf0.mdb.yandexcloud.net:33036	Active	4	31.7 MB / 2.7 GB	0.0 B	2	1	0	98	99	1.8 min (2 s)	169 MB	413.5 KB	502.2 KB	stdout stderr	Thread Dump
5	rc1b-dataproc-d-ljgnr0h3swozkl3z.mdb.yandexcloud.net:39406	Active	4	37.3 MB / 2.7 GB	0.0 B	2	0	0	145	145	1.6 min (2 s)	182.8 MB	658.4 KB	521.1 KB	stdout stderr	Thread Dump

Showing 1 to 6 of 6 entries Previous 1 Next

Обычный flow анализа

Spark 2.4.6 | Jobs | Stages | Storage | Environment | Executors | SQL | PriceStockImport_{{ ds }} application UI

Details for Query 9

Submitted Time: 2021/09/26 10:15:54
Duration: 11 s
Succeeded Jobs: 10

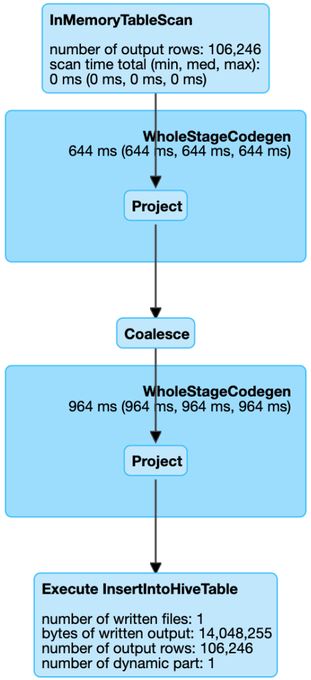

▾ Details

```
== Parsed Logical Plan ==
'InsertIntoTable 'UnresolvedRelation `content_db`.`price_stock`, false, false
+- Project [external_offer_id#10394L, instamart_discount_price_per_item#12731, instamart_discount_price_per_kilo#12854, instamart_discount_price_per_pack#12977, instamart_product_type#9562,
instamart_regular_price_per_item#12362, instamart_regular_price_per_kilo#12485, instamart_regular_price_per_pack#12608, instamart_sku#9561, instamart_sku_id#10763L, max_shop_stock#12116, min_shop_stock#12239,
offer_items_per_pack#10517, offer_name#9556, offer_pack_type#9558, offer_vat#13346, retailer_discount_end#9573, retailer_discount_price_per_item#11624, retailer_discount_price_per_kilo#11747,
retailer_discount_price_per_pack#11870, retailer_discount_start#9572, retailer_partner_price_per_item#11255, retailer_partner_price_per_kilo#11378, retailer_partner_price_per_pack#11501, ... 16 more fields]
   +- Repartition 1, false
      +- Project [external_offer_id#10394L, instamart_discount_price_per_item#12731, instamart_discount_price_per_kilo#12854, instamart_discount_price_per_pack#12977, instamart_product_type#9562,
instamart_regular_price_per_item#12362, instamart_regular_price_per_kilo#12485, instamart_regular_price_per_pack#12608, instamart_sku#9561, instamart_sku_id#10763L, max_shop_stock#12116, min_shop_stock#12239,
offer_items_per_pack#10517, offer_name#9556, offer_pack_type#9558, offer_vat#13346, retailer_discount_end#9573, retailer_discount_price_per_item#11624, retailer_discount_price_per_kilo#11747
```

СПАСИБО

АНТОН ПИЛИПЕНКО