

# > Конспект > 7 урок > Практика: Разворачиваем Spark Kubernetes

## > Оглавление

- > Оглавление
- > Почему стоит запускать Spark в Kubernetes
- > Spark и Kubernetes
  - > spark-submit
  - > Spark Operator
  - > Сравнение быстродействия
- > Особенности Spark в Kubernetes

# > Почему стоит запускать Spark в Kubernetes

• Изоляция сред (контейнеризация и dependency management). Обновив версию Spark, столкнемся с проблемой, что старые job's написанные на предыдущий версии перестали работать или работая, выдают другой результат. Spark в Kubernetes поможет избежать этого, так как каждый наш процессор упакован в отдельный контейнер и запуская новую версию,

- запуск будет происходить в отдельном контейнере. Следовательно в одном кластере, может работать несколько версий Spark, так же все зависимости упаковываются в docker-контейнеры).
- Управление ресурсами. В классическом hadoop и кластере идет борьба за ресурсы, ресурсов не хватает на всех дата-инженеров, и они не могут все одновременно запустить свою job. Работая с Kubernetes, который поддерживает быстрое масштабирование, можно добавить десятки или сотни Node и соотвественно получить новые ресурсы для запуска приложений. Так же, если не запускается Spark приложение, он может масштабироваться в меньшую сторону и это позволяет эффективно использовать ресурсы.
- Гибкое масштабирование.
- Разделение storage и compute слоев. В Spark в Kubernetes наши данные лежат в s3 или в какой нибудь внешней системе (может быть hadoop, в котором, например, не хватило ядер). Запустив Spark в Kubernetes, получим нужное количество ядер и памяти, он возьмет данные из сторонней системе, обработает и по завершению работы данные запишутся в постоянных слоях.

# > Spark и Kubernetes

Спарк можно заупускать в кубере с версии 2.3 (2018г), до версии 3.1 это фича считалась экперементальной.

#### Есть два способа запуска:

- spark-submit (традиционный способ запуска, похоже, на то как запускали бы свою job).
- Kubernetes Operator for Spark (использование специального оператора для Spark).

## > spark-submit

Например, у нас есть некий клиент. Создается классическая строка spark-submit в которой указывается, что кластером будет выступать Kuber. Выполняя команду, отправляем ее в scheduler Kuber, внутри которого запустится Spark driver, который будет отвечать за запуск отдельных Executor'a.

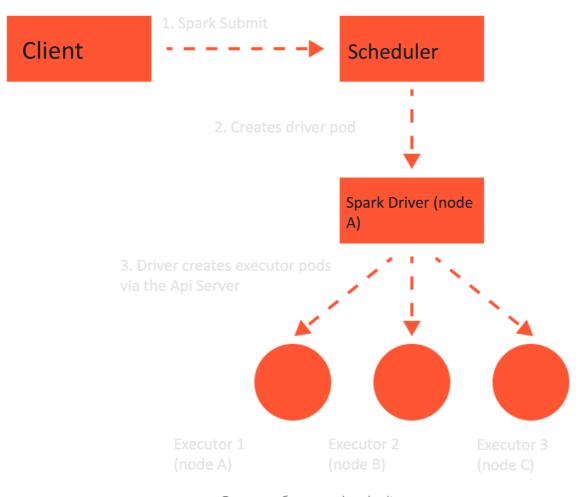


Схема работы spark-submit

- 1. Клиент создает Spark driver внутри k8s Pod.
- 2. Driver создает executors внутри k8s Pod, подключается к ним и использует код приложения.
- 3. Когда исполнение кода завершено, executor pods убиваются, driver же остается в статусе completed.

## > Spark Operator

Использует кастомные ресурсы внутри Kuber, которые отвечают за работу со Spark. Используя Spark Operator, Kuber понимает, что работает Spark внутри него, появляется возможность действовать со Spark-job, как со специфическим Spark приложением.

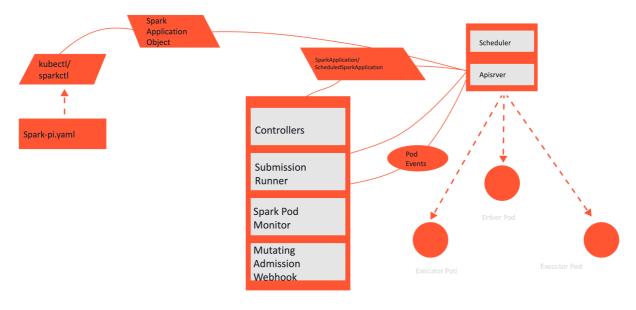
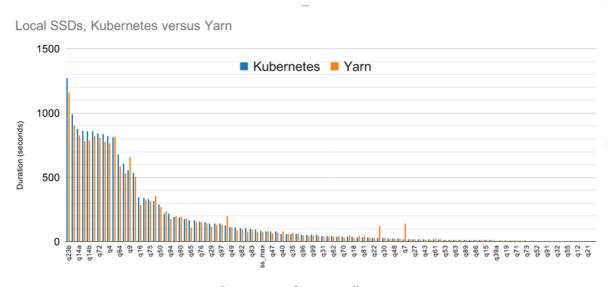


Схема работы Spark Operator

- Spark Application Controller
- · Submission runner
- Spark Pod Monitor
- Mutating Admission Webhook

## > Сравнение быстродействия

Spark в классическом варианте быстрее, но не намного, всего лишь 4-5%. <u>Ссылка</u> на статью.



Сравнение быстродействия

# > Особенности Spark в Kubernetes

- Быстродействие зависит от типа используемых дисков для временных файлов. Например, в облаках быстродействие будет меньше, чем на диске который внутри машины. Так же влияет тип диска SSD и HDD. Используя разные типы дисков, всегда будут разные результаты производительности.
- При сайзинге экзекьюторов необходимо учитывать потребление ресурсов на Node самим Kubernetes, сторонними сервисами. Самому Kubernetes на каждой Node необходимы ресурс под агенты самого же Kuber'а, они сами потребляют оперативку и ресурсы процессора, поэтому нужно оставлять запас.
- Dynamic Allocation работает в Kuber'e по-другому для Spark. Работает для тех экзьютеров, на которые нету persistent данных в хранилище.